

Bike Buyers

Customer Persona Analysis

Oleh : Daffa Aryo Utomo Sudranto
Program Bootcamp : Data Analyst (Dibimbing.id)
Tahun : 2026



Education



Universitas Indonesia - Teknik Elektro
09/2017 - 01/2022



Dibimbing.id - Data Analyst
04/2022 - Present



Revou - Digital Marketing
05/2022 - 08/2022

Experience



Co-Owner
Aquarium Indonesia Pangandaran (Aquarium Publik)
12/2022 - 3/2026



Paid Ads Digital Marketer
Somethinc BeautyHaul (Produk Kecantikan)
9/2022 - 12/2022



Performance Digital Marketing
Harisenin.com (Platform Edukasi)
9/2022 - 12/2022



Previous Data Analitic Project

Data Analysis with SQL: Olist Dataset (Brazilian e-commerce).

Data Preprocessing: Bike Buyers Dataset

Analisa Kondisi Perusahaan berdasarkan Umur & Masa Jabatan Pegawai

Daffa Aryo Utomo Sudranto
Data Analyst

Let's connect



daffa.sudranto@gmail.com



[linkedin.com/in/daffaaryo](https://www.linkedin.com/in/daffaaryo)

PROBLEM STATEMENT

"Berdasarkan riset dari **McKinsey & Company (2021)**, personalisasi merupakan pendorong utama pertumbuhan bisnis di mana perusahaan yang unggul dalam segmentasi mampu mencapai pendapatan **40% lebih tinggi**. Dari artikel tersebut, dikatakan bahwa, sebanyak **71%** konsumen mengharapkan perusahaan memberikan **interaksi yang terpersonalisasi**, dan **76% merasa frustrasi** jika pesan atau pendekatan pemasaran terlalu umum (**generic**).

Oleh karena itu, penentuan **persona pembeli** sepeda dalam analisis ini—yang berfokus pada **analisa informasi pribadi responden**—menjadi krusial agar strategi komunikasi pemasaran tepat sasaran.”

Sumber: McKinsey & Company - The value of getting personalization right—or wrong—is multiplying



Content

ABOUT DATA	01
DATA PREPARATION	02
DATA ISSUES	03
HANDLING DATA ISSUES	04
DATA EXPLORATION	05
CONCLUSION & SUGGESTION	06



About Data


Nama Kolom	Deskripsi	Tipe Data
ID	Identitas (unik) untuk setiap responden dalam dataset	Numerikal - Integer
Marital Status	Status pernikahan responden	Categorical - Object
Gender	Jenis kelamin responden	Categorical - Object
Income	Pendapatan tahunan responden	Numerikal - float
Children	Jumlah anak yang dimiliki oleh responden	Numerikal - float
Education	Tingkat pendidikan terakhir responden	Categorical - Object
Occupation	Kategori pekerjaan responden	Categorical - Object
Home Owner	Status kepemilikan rumah	Categorical - Object
Cars	Jumlah kendaraan (mobil) yang dimiliki responden	Numerikal - float
Commute Distance	Jarak tempuh perjalanan responden dari rumah ke tempat kerja	Categorical - Object
Region	Wilayah atau daerah tempat tinggal responden	Categorical - Object
Age	Usia responden dalam satuan tahun	Numerikal - float
Purchased Bike	Kolom target yang menunjukkan apakah responden membeli sepeda atau tidak	Categorical - Object

Dataset: Bike Buyers

Dataset ini berisi data survei kepemilikan sepeda yang diisi dengan informasi pribadi responden.

Informasi Dataset

- Baris : 1000
- Kolom : 13
- Format File : Comma-Separated Values (CSV)
- Sumber : [kaggle](#)(Klik untuk menuju website)
- Tahun Publikasi : 2020



Import Data

IMPORT DATA



Tools : Jupyter Notebook
Bahasa Pemrograman : Python
Python Library : Pandas

- Dataset bike_buyers diformat sebagai file CSV. Untuk menyajikan data yang bersih, data perlu dibersihkan dengan lingkungan Python.
- Pandas library digunakan untuk mengimpor data mentah, mengubah file CSV menjadi DataFrame, dan menampilkan informasi dataset
- Dengan format DataFrame, lingkungan Python akan dapat membersihkan, mengubah, dan menerapkan metode analitik untuk menyajikan data yang bersih dan informatif

Isi 5 baris teratas :

	ID	Marital Status	Gender	Income	Children	Education	Occupation	Home Owner	Cars	Commute Distance	Region	Age	Purchased Bike
0	12496	Married	Female	40000.0	1.0	Bachelors	Skilled Manual	Yes	0.0	0-1 Miles	Europe	42.0	No
1	24107	Married	Male	30000.0	3.0	Partial College	Clerical	Yes	1.0	0-1 Miles	Europe	43.0	No
2	14177	Married	Male	80000.0	5.0	Partial College	Professional	No	2.0	2-5 Miles	Europe	60.0	No
3	24381	Single	NaN	70000.0	0.0	Bachelors	Professional	Yes	1.0	5-10 Miles	Pacific	41.0	Yes
4	25597	Single	Male	30000.0	0.0	Bachelors	Clerical	No	0.0	0-1 Miles	Europe	36.0	Yes

Data Overview

DATA OVERVIEW

Inspect columns, data count, & data types

Dataset General Information

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1000 entries, 0 to 999
Data columns (total 13 columns):
#   Column              Non-Null Count  Dtype
---  -
0   ID                  1000 non-null  int64
1   Marital Status      993 non-null   object
2   Gender              989 non-null   object
3   Income              994 non-null   float64
4   Children            992 non-null   float64
5   Education            1000 non-null   object
6   Occupation          1000 non-null   object
7   Home Owner          996 non-null   object
8   Cars                991 non-null   float64
9   Commute Distance    1000 non-null   object
10  Region              1000 non-null   object
11  Age                 992 non-null   float64
12  Purchased Bike      1000 non-null   object
dtypes: float64(4), int64(1), object(8)
memory usage: 101.7+ KB
```

Temuan:

- Kolom **Marital Status**, **Gender**, **Income**, **Children**, **Home Owner**, **Cars**, dan **Age** memiliki **data kurang dari 1000** pada Non-null count. Ini menunjukkan adanya **nilai yang hilang (Missing Value)** di kolom tersebut yang memerlukan penanganan lebih lanjut dalam proses pembersihan data.
- Berdasarkan tipe data setiap kolom, terdapat **tipe data yang kurang sesuai**, seperti:
 - Children: float (Int lebih tepat)
 - Cars: float: float (int lebih tepat)
 - Age: float(Int lebih tepat)
- hal tersebut biasa terjadi ketika terapat nilai yang hilang pada kolom tersebut.
- Kolom dengan **penamaan menggunakan spasi (" ")**, yang kurang ideal untuk envirotment dengan bahasa python (dapat menyebabkan syntax error).



DATA OVERVIEW

Inspect columns statistics (numerical data)






Dataset Statistics (Data Numerikal)

	ID	Income	Children	Cars	Age
count	1000.000000	994.000000	992.000000	991.000000	992.000000
mean	19965.992000	56267.605634	1.910282	1.455096	44.181452
std	5347.333948	31067.817462	1.626910	1.121755	11.362007
min	11000.000000	10000.000000	0.000000	0.000000	25.000000
25%	15290.750000	30000.000000	0.000000	1.000000	35.000000
50%	19744.000000	60000.000000	2.000000	1.000000	43.000000
75%	24470.750000	70000.000000	3.000000	2.000000	52.000000
max	29447.000000	170000.000000	5.000000	4.000000	89.000000

Inspection findings:

- Pada **kolom income**, terdapat rentan data numerik yang lebar (**min: 10.000**; **max: 170.000**), serta memiliki nilai mean: **56.267**. Rentan nilai tersebut dapat mengindikasikan terdapat **distribusi data yang tidak normal** dan terdapat nilai dengan **nominal abnormal** sehingga dapat menyebabkan perhitungan statistik menjadi rusak atau bias.
- Hal serupa terjadi pada kolom Age dan Cars. Dimana rentan nilai pada **kolom Age** cukup besar dalam konteks umur (**min: 25**; **max: 89**). Sedangkan pada **kolom Cars**, nilai **median(50%): 1**, namun nilai **max: 4**.
- Terdapat perbedaan **skala yang cukup jauh** (contoh: income dalam puluhan ribu, sedangkan Cars dalam satuan)

Histogram Kolom Numerik



DATA OVERVIEW

Inspect columns statistics (categorical data)



Dataset Statistics (Data Kategorikal)

	Marital Status	Gender	Education	Occupation	Home Owner	Commute Distance	Region	Purchased Bike
count	993	989	1000	1000	996	1000	1000	1000
unique	2	2	5	5	2	5	3	2
top	Married	Male	Bachelors	Professional	Yes	0-1 Miles	North America	No
freq	535	500	306	276	682	366	508	519

Dataset Object Unique Value

	column_name	unique_value	n_unique
0	Marital Status	[Married, Single]	2
1	Gender	[Female, Male]	2
2	Education	[Bachelors, Partial College, High School, Partial High School, Graduate Degree]	5
3	Occupation	[Skilled Manual, Clerical, Professional, Manual, Management]	5
4	Home Owner	[Yes, No]	2
5	Commute Distance	[0-1 Miles, 2-5 Miles, 5-10 Miles, 1-2 Miles, 10+ Miles]	5
6	Region	[Europe, Pacific, North America]	3
7	Purchased Bike	[No, Yes]	2

Temuan:

- Terdapat kolom kategorikal (nominal) dengan 2 nilai (Binary): **Marital Status, Gender, Home Owner, Purchased Bike**
- Terdapat kolom kategorikal (multiclass) dengan nilai yang memiliki tingkatan (ordinal): **Education, Commute Distance**
- Terdapat kolom kategorikal (multiclass) dengan nilai yang tidak memiliki tingkatan: **Occupation, Region**
- Dataset cenderung **tidak memiliki kesalahan penulisan (typo) dan kategori yang sama**, serta penulisan ditulis dengan huruf besar diawal kata

Data reparation

DATA PREPARATION

Penamaan kembali kolom Dataset

- Menghapus spasi tersembunyi dan mengganti spasi (“ ”) diantara kata dengan underscore “_”

Before:

```
Index(['ID', 'Marital Status', 'Gender', 'Income', 'Children', 'Education',  
      'Occupation', 'Home Owner', 'Cars', 'Commute Distance', 'Region', 'Age',  
      'Purchased Bike'],
```


After:

```
Index(['ID', 'Marital_Status', 'Gender', 'Income', 'Children', 'Education',  
      'Occupation', 'Home_Owner', 'Cars', 'Commute_Distance', 'Region', 'Age',  
      'Purchased_Bike'],
```

Missing Value

- Terdapat nilai kosong di beberapa kolom sebesar 5.3% dari seluruh dataset

	missing_value	percentage(%)
Gender	11	1.1
Cars	9	0.9
Children	8	0.8
Age	8	0.8
Marital Status	7	0.7
Income	6	0.6
Home Owner	4	0.4
Jumlah missing value: 53		
Persentase missing value (%): 5.3		



Missing Value Handling

- **Gender (1.1%) - Missing Value Terbanyak**
 - Mengisi nilai yang hilang dengan **kategori baru “Unknown”**
 - Diketahui komposisi **male adalah 50%**. Jika mengisi value dengan data kosong dengan male/female, berpotensi menyebabkan bias pada data, sehingga menambah kategori Unkown cenderung lebih aman dan dapat mempertahankan data lainnya.

Before:

Gender	
Male	50.0
Female	48.9

After:

Gender	
Male	50.0
Female	48.9
Unknown	1.1

- **Marital_Status (0.7%)**
 - Mengisi missing value dengan **Imputation**
 - Diketahui komposisi Marital_Status dengan nilai Married yang memiliki rumah (Home_Owner == ‘Yes’) **sebesar 64%**.
 - Dari temuan tersebut, jika terdapat data kosong namun memiliki nilai ‘Yes’ pada kolom Home_Owner, maka diisi dengan “Married”. Dengan temuan tersebut, **kemungkinan benar dalam mengisi data menjadi 64%**.

	count	percentage
Marital_Status		
Married	438	64.22
Single	240	35.19

- **Home_Owner (0.4%)**
 - Mengisi missing value dengan **Imputation**
 - Diketahui komposisi Home_Owner dengan nilai ‘Yes’ yang memiliki anak (Children > 0) **sebesar 74%**.
 - Dari temuan tersebut, jika terdapat data kosong namun memiliki nilai lebih dari 0 (not) pada kolom Children, maka diisi dengan “Yes”. Dengan temuan tersebut, **kemungkinan benar dalam mengisi data menjadi 74%**.

	count	percentage
Home_Owner		
No	183	25.21
Yes	540	74.38

- **Cars (0.9%), Children(0.8%), Age (0.8%), & Income(0.6%)**
 - Mengisi nilai yang hilang dengan nilai **Median** tiap kolom
 - Nilai median lebih **tahan terhadap outlier** pada data numerik dalam melakukan analisa statistik, sehingga distribusi dataset dan nilai statistika **tidak mengalami perubahan signifikan**

Before:

	Income	Children	Cars	Age
count	994.000000	992.000000	991.000000	992.000000
mean	56267.605634	1.910282	1.455096	44.181452
std	31067.817462	1.626910	1.121755	11.362007
min	10000.000000	0.000000	0.000000	25.000000
25%	30000.000000	0.000000	1.000000	35.000000
50%	60000.000000	2.000000	1.000000	43.000000
75%	70000.000000	3.000000	2.000000	52.000000
max	170000.000000	5.000000	4.000000	89.000000

After:

	Income	Children	Cars	Age
count	1000.000000	1000.000000	1000.000000	1000.000000
mean	56290.000000	1.911000	1.451000	44.172000
std	30975.722678	1.620403	1.117519	11.316912
min	10000.000000	0.000000	0.000000	25.000000
25%	30000.000000	0.000000	1.000000	35.000000
50%	60000.000000	2.000000	1.000000	43.000000
75%	70000.000000	3.000000	2.000000	52.000000
max	170000.000000	5.000000	4.000000	89.000000

Outlier & Abnormal Value

- Menggunakan metode IQR untuk mendapatkan nilai batas atas dan batas bawah sebagai acuan dalam menentukan nilai yang dianggap outlier pada kolom Income dan Age


IQR Methode:

	ID	Income	Children	Cars	Age
lower_bond	1520.75	-30000.0	-4.5	-0.5	9.5
upper_bond	38240.75	130000.0	7.5	3.5	77.5
n_outlier	0.00	10.0	0.0	59.0	4.0
percentage	0.00	1.0	0.0	5.9	0.4

Penanganan Outlier

- Seluruh outlier dibiarkan** karena nilai yang dianggap outlier adalah nilai-nilai yang dianggap wajar pada real case
- contoh:** pekerja yang memiliki gaji diatas 130.000 (Max: 170.000) memang ada keberadaannya, namun populasinya tidak banyak

Boxplot:



DATA PREPARATION

Data Types Validity

- Setelah seluruh data kolom terisi, tipe data pada kolom yang berisikan data numerikal (Children, Cars, & Age) dapat diubah dari tipe float menjadi int
- Tipe data numerikal diubah karena untuk ketiga kolom tersebut seharusnya berisikan angka bilangan bulat, bukan desimal

Code:

```
type_columns = ["Children", "Cars", "Age"]

for col in type_columns:
    dfc[col] = dfc[col].astype(int)
```

Before:

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1000 entries, 0 to 999
Data columns (total 13 columns):
#   Column                Non-Null Count  Dtype
---  -
0   ID                    1000 non-null  int64
1   Marital_Status        1000 non-null  object
2   Gender                1000 non-null  object
3   Income                1000 non-null  float64
4   Children              1000 non-null  float64
5   Education              1000 non-null  object
6   Occupation             1000 non-null  object
7   Home_Owner            1000 non-null  object
8   Cars                  1000 non-null  float64
9   Commute_Distance      1000 non-null  object
10  Region                1000 non-null  object
11  Age                   1000 non-null  float64
12  Purchased_Bike        1000 non-null  object
dtypes: float64(4), int64(1), object(8)
memory usage: 101.7+ KB
```

After:

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1000 entries, 0 to 999
Data columns (total 13 columns):
#   Column                Non-Null Count  Dtype
---  -
0   ID                    1000 non-null  int64
1   Marital_Status        1000 non-null  object
2   Gender                1000 non-null  object
3   Income                1000 non-null  float64
4   Children              1000 non-null  int64
5   Education              1000 non-null  object
6   Occupation             1000 non-null  object
7   Home_Owner            1000 non-null  object
8   Cars                  1000 non-null  int64
9   Commute_Distance      1000 non-null  object
10  Region                1000 non-null  object
11  Age                   1000 non-null  int64
12  Purchased_Bike        1000 non-null  object
dtypes: float64(1), int64(4), object(8)
memory usage: 101.7+ KB
```


DATA PREPARATION



Duplicate

- Setelah sluruh kolom terisi dan “bersih”, dataframe diperiksa nilai duplikatnya
- Untuk dataframe ini tidak ditemukan duplikat

Code:

```
dfc.duplicated().sum()
```

Hasil:

```
np.int64(0)
```

Before Data Cleaning

	ID	Marital Status	Gender	Income	Children	Education	Occupation	Home Owner	Cars	Commute Distance	Region	Age	Purchased Bike
0	12496	Married	Female	40000.0	1.0	Bachelors	Skilled Manual	Yes	0.0	0-1 Miles	Europe	42.0	No
1	24107	Married	Male	30000.0	3.0	Partial College	Clerical	Yes	1.0	0-1 Miles	Europe	43.0	No
2	14177	Married	Male	80000.0	5.0	Partial College	Professional	No	2.0	2-5 Miles	Europe	60.0	No
3	24381	Single	NaN	70000.0	0.0	Bachelors	Professional	Yes	1.0	5-10 Miles	Pacific	41.0	Yes
4	25597	Single	Male	30000.0	0.0	Bachelors	Clerical	No	0.0	0-1 Miles	Europe	36.0	Yes

After Data Cleaning

	ID	Marital Status	Gender	Income	Children	Education	Occupation	Home Owner	Cars	Commute Distance	Region	Age	Purchased Bike
0	12496	Married	Female	40000.0	1.0	Bachelors	Skilled Manual	Yes	0.0	0-1 Miles	Europe	42.0	No
1	24107	Married	Male	30000.0	3.0	Partial College	Clerical	Yes	1.0	0-1 Miles	Europe	43.0	No
2	14177	Married	Male	80000.0	5.0	Partial College	Professional	No	2.0	2-5 Miles	Europe	60.0	No
3	24381	Single	Unknown	70000.0	0.0	Bachelors	Professional	Yes	1.0	5-10 Miles	Pacific	41.0	Yes
4	25597	Single	Male	30000.0	0.0	Bachelors	Clerical	No	0.0	0-1 Miles	Europe	36.0	Yes

Before Data Cleaning

	ID	Income	Children	Cars	Age
count	1000.000000	994.000000	992.000000	991.000000	992.000000
mean	19965.992000	56267.605634	1.910282	1.455096	44.181452
std	5347.333948	31067.817462	1.626910	1.121755	11.362007
min	11000.000000	10000.000000	0.000000	0.000000	25.000000
25%	15290.750000	30000.000000	0.000000	1.000000	35.000000
50%	19744.000000	60000.000000	2.000000	1.000000	43.000000
75%	24470.750000	70000.000000	3.000000	2.000000	52.000000
max	29447.000000	170000.000000	5.000000	4.000000	89.000000

After Data Cleaning

	ID	Income	Children	Cars	Age
count	1000.000000	1000.000000	1000.000000	1000.000000	1000.000000
mean	19965.992000	56290.000000	1.911000	1.451000	44.172000
std	5347.333948	30975.722678	1.620403	1.117519	11.316912
min	11000.000000	10000.000000	0.000000	0.000000	25.000000
25%	15290.750000	30000.000000	0.000000	1.000000	35.000000
50%	19744.000000	60000.000000	2.000000	1.000000	43.000000
75%	24470.750000	70000.000000	3.000000	2.000000	52.000000
max	29447.000000	170000.000000	5.000000	4.000000	89.000000

Before Data Cleaning

```
<class 'pandas.core.frame.DataFrame'>  
RangeIndex: 1000 entries, 0 to 999  
Data columns (total 13 columns):  
#   Column                Non-Null Count  Dtype  
---  ---  
0   ID                     1000 non-null   int64  
1   Marital Status         993 non-null    object  
2   Gender                 989 non-null    object  
3   Income                 994 non-null    float64  
4   Children               992 non-null    float64  
5   Education              1000 non-null   object  
6   Occupation             1000 non-null   object  
7   Home Owner            996 non-null    object  
8   Cars                  991 non-null    float64  
9   Commute Distance       1000 non-null   object  
10  Region                1000 non-null   object  
11  Age                   992 non-null    float64  
12  Purchased Bike         1000 non-null   object  
dtypes: float64(4), int64(1), object(8)  
memory usage: 101.7+ KB
```

After Data Cleaning

```
<class 'pandas.core.frame.DataFrame'>  
RangeIndex: 1000 entries, 0 to 999  
Data columns (total 13 columns):  
#   Column                Non-Null Count  Dtype  
---  ---  
0   ID                     1000 non-null   int64  
1   Marital_Status         1000 non-null   object  
2   Gender                 1000 non-null   object  
3   Income                 1000 non-null   float64  
4   Children               1000 non-null   int64  
5   Education              1000 non-null   object  
6   Occupation             1000 non-null   object  
7   Home Owner            1000 non-null   object  
8   Cars                  1000 non-null   int64  
9   Commute_Distance       1000 non-null   object  
10  Region                1000 non-null   object  
11  Age                   1000 non-null   int64  
12  Purchased_Bike         1000 non-null   object  
dtypes: float64(1), int64(4), object(8)  
memory usage: 101.7+ KB
```

Before Data Cleaning

	Marital Status	Gender	Education	Occupation	Home Owner	Commute Distance	Region	Purchased Bike
count	993	989	1000	1000	996	1000	1000	1000
unique	2	2	5	5	2	5	3	2
top	Married	Male	Bachelors	Professional	Yes	0-1 Miles	North America	No
freq	535	500	306	276	682	366	508	519

After Data Cleaning

	Marital_Status	Gender	Education	Occupation	Home_Owner	Commute_Distance	Region	Purchased_Bike
count	1000	1000	1000	1000	1000	1000	1000	1000
unique	2	3	5	5	2	5	3	2
top	Married	Male	Bachelors	Professional	Yes	0-1 Miles	North America	No
freq	539	500	306	276	686	366	508	519

DATA PREPARATION



Pengambilan Sample data:

- Setelah seluruh data terisi, dilakukan pengambilan **data sample sebesar 20%** dari data setelah dilakukan cleaning
- Dataset sample dilakukan perbandingan dengan data set clean

Data Asli

===Statistik Dasar Cleaned Dataframe Asli (Numerik)===					
	ID	Income	Children	Cars	Age
count	1000.000000	1000.000000	1000.000000	1000.000000	1000.000000
mean	19965.992000	56290.000000	1.911000	1.451000	44.172000
std	5347.333948	30975.722678	1.620403	1.117519	11.316912
min	11000.000000	10000.000000	0.000000	0.000000	25.000000
25%	15290.750000	30000.000000	0.000000	1.000000	35.000000
50%	19744.000000	60000.000000	2.000000	1.000000	43.000000
75%	24470.750000	70000.000000	3.000000	2.000000	52.000000
max	29447.000000	170000.000000	5.000000	4.000000	89.000000

Data Sample

===Statistik Dasar Dataframe Sample 20% (Numerik)===					
	ID	Income	Children	Cars	Age
count	200.000000	200.000000	200.000000	200.000000	200.000000
mean	19984.995000	59600.000000	2.160000	1.555000	45.175000
std	5427.873553	31380.946753	1.633321	1.128424	10.955111
min	11090.000000	10000.000000	0.000000	0.000000	26.000000
25%	15471.250000	40000.000000	1.000000	1.000000	37.000000
50%	19736.000000	60000.000000	2.000000	2.000000	43.000000
75%	24773.000000	80000.000000	4.000000	2.000000	53.000000
max	29380.000000	170000.000000	5.000000	4.000000	78.000000

Temuan Dataset Sample Numerik:

- Jumlah row: 200
- Terdapat perbedaan pada kolom **nilai max ID, median Children, dan nilai max Age**

Data Asli

===Statistik Dasar Cleaned Dataframe Asli (Object)===					
	Marital_Status	Gender	Income_Category	Having_Children	Education
count	1000	1000	1000	1000	1000
unique	2	3	4	2	5
top	Married	Male	Low	Yes	Bachelors
freq	539	500	434	726	306

	Occupation	Home_Owner	Car_Owner	Commute_Distance	Region
count	1000	1000	1000	1000	1000
unique	5	2	2	5	3
top	Professional	Yes	Yes	0-1 Miles	North America
freq	276	685	762	366	508

	Age_Group	Purchased_Bike
count	1000	1000
unique	4	2
top	Middle Aged	No
freq	618	519

Data Sample

===Statistik Dasar Dataframe Sample 20% (Object)===					
	Marital_Status	Gender	Income_Category	Having_Children	Education
count	200	200	200	200	200
unique	2	3	4	2	5
top	Married	Female	Low	Yes	Bachelors
freq	114	101	78	156	62

	Occupation	Home_Owner	Car_Owner	Commute_Distance	Region
count	200	200	200	200	200
unique	5	2	2	5	3
top	Professional	Yes	Yes	0-1 Miles	North America
freq	60	134	156	67	106

	Age_Group	Purchased_Bike
count	200	200
unique	4	2
top	Middle Aged	No
freq	123	106

Temuan Dataset Sample Object:

- Jumlah row: 200
- Untuk nilai unique dan top nya tidak ada perbedaan
- namun, hanya frekuensinya yang berbeda

Feature Engineering

FEATURE ENGINEERING



Membuat kategori baru & Encoding

Membuat Kategori Baru

- Membuat kategori untuk kolom numerik: Income, Age, Children, & Cars
- Kolom baru untuk menentukan kategori berdasarkan rentan nilai tertentu

Nama Kolom	Kriteria	Tipe Data
Income_Category	- Income <= 40.000: Low - Income <= 70.000: Middle - Income <= 110.000: High - Income > 110.000: Ultra High	Categorical - Object
Age_Group	- Age <= 30: Young Adult - Age <= 50: Middle Aged - Age <= 70: Senior - Age > 70: Old	Categorical - Object
Having_Children	- Children > 0: Yes - Children = 0: No	Categorical - Object
Car_Owner	- Cars > 0: Yes - Cars = 0: No	Categorical - Object

Encoding

- Mengubah bentuk kolom dengan tipe data object ke dalam bentuk numerikal. Metode Encoding yang dipilih disesuaikan dengan karakter data object pada tiap kolom
- Label Encoder:** Digunakan untuk mengubah kategori pada kolom object yang **tidak memiliki tingkatan atau biner** (yes/no atau hanya 2 kategori). **Kolom: Purchased_Bike, Marital_Status, Gender, Occupation, Home_Owner, Region**
- Ordinal Encoder:** Digunakan untuk mengubah kategori pada kolom object yang memiliki tingkatan. Kolom: Commute_Distance, Education,

Encode_PB	Encode_MS	Encode_Gen	Encode_Oc	Encode_HO	Encode_Re	Encode_CD	Encode_Ed
0	0	0	4	1	0	0.0	3.0
0	0	1	0	1	0	0.0	2.0
0	0	1	3	0	0	2.0	2.0
1	1	2	3	1	2	3.0	3.0
1	1	1	0	0	0	0.0	3.0

Data Exploration


DATA EXPLORATION

Distribusi Data

Pemeriksaan Distribusi Data


- Menggunakan metode Probability Mass Function (PDF)
- PDF digunakan untuk peubah acak kontinu. Menunjukkan kepadatan probabilitas di tiap titik X

Histogram Density Kolom Numerik




Income Distribution (PDF)

- Distribusi Income cenderung **right-skewed**, karena data mayoritas pada rentan gaji **10.000 - 70.000**
- Density terendah kemungkinan gaji dari responden dengan jabatan tinggi pada perusahaan besar




Children Distribution (PDF)

- Distribusi Children cenderung **simetris/uniform**, karena tingkat perbedaan density tidak signifikan



Cars Distribution (PDF)

- Distribusi Cars cenderung **right-skewed**, karena data mayoritas pada rentan **0 - 2**
- Density paling rendah pada nilai 4, karena memiliki 4 mobil memang bukan kebiasaan mayoritas responden



Age Distribution (PDF)

- Distribusi Age cenderung **right-skewed**, karena data mayoritas pada **rentan umur 25 - 50**
- Density paling rendah mulai dari umur 70 keatas, dimana data tersebut adalah representasi responden lanjut usia (Lansia)

DATA EXPLORATION

Distribusi Data


Uji Distribusi Normal

- Menggunakan metode Shapiro
- Uji Shapiro merupakan uji statistik untuk memeriksa normalitas distribusi.
- P-Value pada uji shapiro menentukan normalitas, jika P-Value ≥ 0.05 . Sebaliknya, jika P-Value < 0.05 , maka distribusi data tidak normal

	Kolom	Skewness	Statistic	P-Value	Kesimpulan
0	Encode_MS	0.156712	0.634375	1.121998e-41	Tidak Normal
1	Encode_Gen	0.145606	0.673930	5.020699e-40	Tidak Normal
2	Income	0.751168	0.944142	5.688197e-19	Tidak Normal
3	Children	0.393232	0.892520	8.013958e-26	Tidak Normal
4	Encode_Ed	-0.284322	0.907397	3.653705e-24	Tidak Normal
5	Encode_Oc	-0.303832	0.862256	1.026786e-28	Tidak Normal
6	Encode_HO	-0.797725	0.584786	1.497995e-43	Tidak Normal
7	Cars	0.429246	0.887892	2.653775e-26	Tidak Normal
8	Encode_CD	0.368967	0.847276	5.754838e-30	Tidak Normal
9	Encode_Re	0.147076	0.802242	3.190279e-33	Tidak Normal
10	Age	0.527930	0.969976	1.628964e-13	Tidak Normal
11	Encode_PB	0.076169	0.636066	1.310637e-41	Tidak Normal


Temuan:

- Semua kolom numerik memiliki distribusi yang tidak normal




DATA EXPLORATION

Distribusi Data



Kerapatan/Density Data Income berdasarkan Income Category

- Variasi data terlebar terdapat pada **Income Category low**
- Density tertinggi ada terdapat pada **Income Category Middle** pada rentan **60.000 - 70.000**




Kerapatan/Density Data Age berdasarkan Age Group

- Variasi data terlebar terdapat pada **Age Group Middle Aged**
- Density tertinggi ada terdapat pada **Age Group Middle Aged** pada rentan **35 - 45 Tahun**

DATA EXPLORATION

Hubungan / Korelasi

Heatmap Korelasi Kolom Numerik Data Clean




Temuan pada Heatmap:

- Secara umum, tingkat hubungan cenderung tidak terlalu kuat
- Namun, masih terdapat hubungan antar kolom data
- Nilai hubungan terkuat pada heat map:
 - **Age & Children (0.53)**: Dapat diinterpretasikan dengan hubungan antara umur responden dengan jumlah anak yang dimiliki
 - **Cars & Income (0.43)**: Dapat diinterpretasikan dengan hubungan antara jumlah mobil yang dimiliki dengan pendapatan/gaji yang diterima oleh responden


DATA EXPLORATION

Hubungan / Korelasi



Rata-rata umur berdasarkan jumlah anak

- Rata-rata umur tertinggi adalah **51 Tahun** dan terendahnya adalah **33 Tahun**
- Dapat dilihat bahwa terdapat kecenderungan bahwa semakin tinggi nilai rata-rata umur, maka jumlah anak yang dimiliki semakin banyak
- Maka hubungan cenderung kearah positif



Rata-rata pendapatan berdasarkan jumlah mobil


- Rata-rata pendapatan tertinggi sekitar **108.305** dan terendah sekitar **47.227**
- Dapat dilihat bahwa terdapat kecenderungan bahwa semakin tinggi nilai pendapatan, maka jumlah mobil yang dimiliki semakin banyak
- Maka hubungan cenderung kearah positif

DATA EXPLORATION

Density Heatmap

Density Heatmap

- Density heatmap merupakan visualisasi data 2 dimensi untuk dapat melihat hubungan antara 2 variabel
- Warna kotak merepresentasikan jumlah data pada rentang tertentu




Heatmap Density Children vs Age

- Dapat dilihat bahwa pada range umur 30 - 34 yang memiliki anak 0 - 1 memiliki kerapatan yang tinggi
- Dapat dilihat bahwa semakin tua umurnya, warna terisi dibagian atas heatmap atau mengisi warna pada rentang jumlah anak yang lebih banyak

DATA EXPLORATION

Density Heatmap

Density: Income vs Cars



Heatmap Density Cars vs Income

- Dapat dilihat bahwa pada rentan Income 60,000 - 70.000 dan jumlah mobil 2 memiliki kerapatan tertinggi
- Dari pola warna, dapat dilihat bawah semakin besar rentan income, warna terisi di heatmap bagian atas atau mengisi retan jumlah mobil yang lebih tinggi

DATA EXPLORATION



Uji Hipotesis Hubungan

Uji Hipotesis dengan Metode Spearman Correlation

- Spearman Correlation adalah uji korelasi berbasis ranking untuk mengukur hubungan antar variabel
- Dapat digunakan untuk menguji ada atau tidaknya hubungan antar 2 variabel
- Metode ini dipilih karena metode ini merupakan uji non-parametrik sehingga data tidak membutuhkan distribusi normal atau hubungan linier
- Jika nilai **Corr > 0** : **Hubungan positif**; Jika nilai **Corr < 0**: **Hubungan negatif**
- Jika **P-Value < 0.05**: **Tolak H0**; Jika **P-Value >= 0.05**: **Gagal Tolak H0**

Intepretasi nilai Corr/rho

Nilai p/rho	Arti
0.00–0.19	Sangat lemah
0.20–0.39	Lemah
0.40–0.59	Sedang
0.60–0.79	Kuat
0.80–1.00	Sangat kuat

Hipotesis dengan Spearman Correlation

H0: Kemungkinan tidak memiliki hubungan

H1: Kemungkina memiliki hubungan yang kuat

Hasil Uji Kolom: Age vs Children

```
Nilai corr/rho: 0.594939201269112
Nilai P-Value: 8.890241873179471e-97
```

```
Corr: 0.594939201269112, korelasi cenderung sangat kuat
P-Value: 8.890241873179471e-97 < 0.05, maka Tolak H0: Terdapat hubungan yang signifikan
```

Hasil Uji Kolom: Cars vs Income

```
Nilai corr/rho: 0.32771135032854193
Nilai P-Value: 1.8293672908724098e-26
```


```
Corr: 0.32771135032854193, korelasi cenderung lemah
P-Value: 1.8293672908724098e-26 < 0.05, maka Tolak H0: Terdapat hubungan yang signifikan
```

DATA EXPLORATION



Hubungan / Korelasi

Heatmap Korelasi Kolom Numerik




Temuan pada Heatmap dengan Encoding:

- Secara umum, tingkat hubungan cenderung tidak terlalu kuat
- Namun, masih terdapat hubungan antar kolom data
- Nilai hubungan yang berhubungan dengan pembelian sepeda pada heat map:
 - **Encode_PB & Cars (-0.20):** Dapat diinterpretasikan dengan, hubungan antara status pembelian sepeda responden dengan jumlah mobil yang dimiliki
 - **Encode_PB & Encode_CD (-0.14):** Dapat diinterpretasikan dengan hubungan antara status pembelian sepeda responden dengan jarak perjalanan responden

DATA EXPLORATION


Bike Purchase Rate by Number of Cars



Tingkat konversi pembelian sepeda berdasarkan jumlah mobil

- Tingkat konversi tertinggi untuk membeli sepeda adalah **61.8%** dan terendah **35.6%**
- Dapat dilihat terdapat kecenderungan bahwa semakin banyak mobil yang dimiliki, maka semakin kecil tingkat konversi untuk membeli sepeda
- Maka hubungan cenderung kearah negatif namun tidak cukup kuat karena urutan jumlah mobil tidak urut dari banyak ke rendah

Bike Purchase Rate by Commute Distance




Tingkat konversi pembelian sepeda berdasarkan Jarak Perjalanan

- Tingkat konversi tertinggi untuk membeli sepeda adalah **58.6%** dan terendah **29.7%**
- Dapat dilihat terdapat kecenderungan bahwa semakin jauh jarak perjalanan responden, maka semakin kecil tingkat konversi untuk membeli sepeda
- Maka hubungan cenderung kearah negatif namun tidak cukup kuat karena urutan jumlah mobil tidak urut dari banyak ke rendah

Insight

INSIGHT: PURCHASE BIKE BY CAR OWNER

Proporsi Pembeli Sepeda (Yes/No)




Purchased_Bike	Jumlah_Responden	Pesentase(%)
No	519	51.9
Yes	481	48.1


Temuan Pie Chart:

- Dari seluruh dataset Bike_Buyers, ditemukan bahwa hanya **48.1% (481 Responden)** dari seluruh populasi yang membeli sepeda
- Angka ini menjadi dasar dalam penentuan **persona pembeli sepeda**

Purchased Bike by Car Owner



Purchased Bike by Car Owner (%)





Temuan Bar Chart:

- Dari **481** Orang yang membeli sepeda, **147** orang tidak memiliki mobil dan **334** orang memiliki mobil.
- Namun jika dibandingkan antar kategori pada kolom Car_Owner, proporsi **pembeli sepeda yang tidak memiliki mobil mencapai nilai 61.76%**
- Maka, responden yang tidak memiliki mobil cenderung melakukan pembelian sepeda





INSIGHT: PURCHASE BIKE BY COMMUTE DISTANCE



Temuan pada Populasi Commute Distance:


- Berdasarkan seluruh responden, **200** dari **481** responden memiliki sepeda serta memiliki jarak tempuh perjalanan sekitar **0-1 Miles**.
- Namun, ketika dibandingkan antar kategori, responden yang memiliki jarak tempuh **2-5 Miles**, lebih cenderung membeli sepeda (proporsi **58.64%**). Artinya terdapat kemungkinan kategori tersebut memiliki **konversi untuk membeli sepeda lebih tinggi** dibanding 0-1 Miles (54.64%)



Temuan pada Populasi Pengguna Sepeda:

- Berdasarkan seluruh pemebli sepeda, **41.6%** (**200 Responden**), memiliki jarak berpergian sekitar **0 - 1 Miles**, serta jarak berpergian terbanyak berikutnya diikuti oleh **2-5 Miles** dan **1 - 2 Miles**
- Maka dari temuan ini, responden yang memiliki sepeda cenderung memiliki jarak berpergian yang tidak terlalu jauh.


INSIGHT: PURCHASE BIKE BY INCOME CATEGORY



Temuan pada populasi Income Category:



- Berdasarkan seluruh responden, kategori **Low** memang mendominasi pembelian sepeda (**201 dari 481 Responden**)
- Namun, ketika dibandingkan antar kategori, responden dengan Income_Category **Ultra High dan Middle** memiliki **potensi konversi yang lebih tinggi** untuk membeli sepeda dengan proporsi **52.54% (Ultra High)** dan **51.50% (Middle)** sedangkan **low hanya sebesar 46.31%**.
- Terdapat kemungkinan bahwa responden dengan Income Ultra High dan Middle untuk kebutuhan lifestyle atau sadar dalam manfaat penggunaan sepeda untuk perjalanan atau kesehatan

INSIGHT: PURCHASE BIKE BY EDUCATION



Temuan pada populasi Education:


- Berdasarkan seluruh responden, **169** dari **481** responden memiliki sepeda dan jenjang edukasi terakhir adalah **Bachelors (Angka tertinggi)**.
- Hal tersebut diperkuat dengan perbandingan tiap kategori, dimana **Bachelors** cenderung untuk membeli sepeda dengan konversi **55.23%** dan diikuti oleh **Graduate Degree (54.02%)**
- Sedangkan **Partial High School** memiliki konversi yang sangat rendah pada **26.32%**



Temuan pada populasi pembeli sepeda:



- Berdasarkan data yang membeli sepeda, responden dengan pendidikan terakhir **Bachelors** menjadi disitribusi mayoritas (**35.1%**) serta diikuti oleh **Partial College (24.7%)** dan **Graduate Degree (19.5%)**
- Dari temuan tersebut, terdapat kemungkinan bahwa responden yang menjalankan pendidikan hingga kuliah memiliki kebiasaan menggunakan sepeda dengan alasan tertentu dibandingkan dengan yang menjalankan pendidikan hingga sekolah.

INSIGHT: PURCHASE BIKE BY AGE GROUP



Temuan pada populasi Age Group:


- Berdasarkan seluruh responden, **334** dari **481** responden memiliki sepeda dan masuk kedalam kelompok umur Middle Ade (31 - 50 Tahun)
- Hal tersebut diperkuat dengan perbandingan tiap kategori, dimana **Middle-Aged** cenderung untuk membeli sepeda dengan konversi **54.05%**
- Sedangkan **Young Adult (Dibawah 25 - 30 Tahun)** memiliki konversi yang cukup rendah pada **35.19%**



Temuan pada populasi pembeli sepeda:



- Berdasarkan data yang membeli sepeda, responden dengan kelompok umur **Middle-Aged(69.4%)** menjadi kelompok mayoritas
- Dari temuan tersebut, maka pada rentan umur tersebut penggunaan sepeda cukup populer

INSIGHT: PURCHASE BIKE BY OCCUPATION



Temuan pada populasi Occupation:

- Berdasarkan seluruh responden, **150 dari 481** responden memiliki sepeda dan memiliki pekerjaan sebagai Professional
- Sedangkan **Young Adult (Dibawah 25 - 30 Tahun)** memiliki konversi yang cukup rendah pada **35.19%**




Temua pada populasi pembeli sepeda:



- Berdasarkan data yang membeli sepeda, responden dengan pekerjaan sebagai **Professional (31.2%)** menjadi kelompok mayoritas
- Dari temuan tersebut, maka pada kelompok pekerjaan tersebut penggunaan sepeda cukup populer untuk alasan tertentu (lifestyle/perjalanan menuju kantor, dll)

INSIGHT: PURCHASE BIKE BY REGION

Region Population(%)



Bike Purchaser by Region



Temuan pada populasi Region:

- Berdasarkan data seluruh responden, konversi pembelian sepeda paling tinggi ada di **region Pasific sebesar 58.85%**
- Namun, untuk data responden yang membeli sepeda, mayoritas berasal dari **North America (45.7%)** karena region tersebut merupakan populasi mayoritas dari seluruh data responden (**50.8%**)

Conclusion & Suggestion

CONCLUSION & SUGGESTION

Practical Urban Commuter



Persona Pembeli Sepeda:

Gender	: Male / Female
Age Range	: 30 - 50 (Middle - Aged)
Occupation	: Professional
Commute Distance	: 0 - 5 Miles (Urban/City Commuting)
Income Range	: 50.000 - 170.000 (Middle - Ultra High)
Education	: Enroll College
Car Owner	: No

Target Region:

- Short Term: **Pacific**
 - Cenderung memiliki tingkat konversi yang tinggi (**58.85%**)
 - Dapat menjadi region utama untuk melakukan campaign (**Core Market**)
- Long Term: **North America**
 - Berpotensi menjadi target market besar
 - Diperlukan untuk **mendedukasi market** sebagai usaha untuk **meningkatkan konversi (49.33%)**

Recommendation:

- Membuat campaign **sesuai dengan persona pembeli sepeda**, yang dilakukan secara **digital maupun konvensional** (billboard/reklame) agar mencakup seluruh calon pembeli potensial
- Meluncurkan produk sepeda **tipe urban atau folding bike** yang cocok untuk bersepeda didalam kota dengan jarak perjalanan **0 - 5 Miles**
- Membuat produk dengan range harga yang sesuai untuk pendapatan dengan kategori Middle serta membuat produk atau produk dengan bundling aksesoris premium untuk calon pembeli dengan kategori pendapatan Ultra High

Reflection:

- Dibutuhkan **jumlah data yang lebih besar** untuk memberikan insight yang lebih akurat
- Dibutuhkan data **tipe datetime**, sehingga dapat dilakukan analisa berdasarkan waktu atau periode tertentu
- Dibutuhkan data numerik lainnya seperti **harga sepeda** yang dibeli